

## Cours 2

### 3 Estimateur de Bayes

Comme nous l'avons déjà fait remarquer, la prise d'une décision, ici le choix d'un estimateur, va engendrer un coût que l'on va quantifier à l'aide de la fonction de perte. En pratique, on cherche une décision qui minimise en moyenne la fonction de coût.

**Définition 5** – On appelle *estimateur de Bayes* associé à un coût  $L$  et à une distribution a priori  $\pi$ , toute décision  $\delta^\pi$  qui minimise le risque de Bayes  $r(\pi, \delta)$ .

On a :

$$\delta^\pi(x) = \underset{\delta \in \mathcal{D}}{\operatorname{Argmin}} r(\pi, \delta)$$

Remarquons que d'après la proposition (1), un estimateur peut également être défini comme étant une décision qui minimise la moyenne suivant la prédictive  $f(x)$  du coût a posteriori.

#### 3.1 Fonctions de coût usuelles

##### 3.1.1 Coût quadratique

**Définition 6** – La fonction de coût quadratique est la fonction définie par :

$$L(\theta, \delta(x)) = (\theta - \delta(x))^2.$$

Une variante de cette fonction de coût est une fonction de coût quadratique pondérée de la forme :  $L(\theta, \delta(x)) = w(\theta)(\theta - \delta(x))^2$ .

**Proposition 2** – Sous l'hypothèse d'un coût quadratique, l'estimateur de Bayes  $\delta^\pi(x)$  de  $\theta$  associé à la loi a priori  $\pi$  est la moyenne a posteriori de  $\theta$  :

$$\delta^\pi(x) = E^{\pi(\cdot|x)}(\theta) = \int_{\theta \in \Theta} L(\theta, \delta(x)) \pi(\theta | x) d\theta.$$

**Preuve :** Par définition, l'estimateur de Bayes minimise le coût a posteriori i.e.  $\rho(\pi, \delta) = E^{\pi(\cdot|x)}[L(\theta, \delta(x))]$ .

Sous l'hypothèse d'un coût quadratique, on a :

$$\begin{aligned} \rho(\pi, \delta) &= E^{\pi(\cdot|x)}[(\theta - \delta(x))^2] \\ &= E^{\pi(\cdot|x)}(\theta^2) - 2\delta(x)E^{\pi(\cdot|x)}(\theta) + \delta^2(x) \end{aligned}$$

Il s'agit d'un polynôme du second degré en  $\delta(x)$ . Il sera minimum en  $E^{\pi(\cdot|x)}(\theta)$ .

**Exemple 1 (suite) :** Dans cet exemple nous avons obtenu une loi gamma inverse de paramètres  $(n + \alpha, \sum_{i=1}^n x_i + \beta)$  comme loi a posteriori. Or l'espérance mathématique d'une loi gamma inverse de paramètres  $(a, b)$  est égale à  $b/(a - 1)$ , on a donc qu'un estimateur de Bayes  $\delta^\pi(x)$  du paramètre  $\theta$ , sous l'hypothèse d'un coût quadratique, est égale à :

$$\tilde{\theta} = (\sum_{i=1}^n x_i + \beta)/(n + \alpha - 1).$$

**Autre exemple :** Si  $X \sim \mathcal{P}(\theta)$  et si  $\pi(\theta)$ , la loi a priori est une loi Gamma de paramètres  $(\alpha, \beta)$ , la loi a posteriori  $\pi(\theta | x)$  est une loi Gamma de paramètres  $(x + \alpha, \beta + 1)$  (voir TD). Sous l'hypothèse d'un coût quadratique, un estimateur de Bayes  $\delta^\pi(x)$  de  $\theta$  sera l'espérance a posteriori de  $\theta$ . Puisque la loi a posteriori est une loi Gamma, l'espérance est le rapport des paramètres et on a :

$$\delta^\pi(x) = (x + \alpha)/(\beta + 1).$$

### 3.1.2 Coût absolu

**Définition 7** – La fonction de coût absolue est la fonction définie par :

$$L(\theta, \delta(x)) = \begin{cases} k_2(\theta - \delta(x)) & \text{si } \theta > \delta(x), \\ k_1(\delta(x) - \theta) & \text{sinon.} \end{cases}$$

**Proposition 3** – Un estimateur de Bayes associé à  $\pi$  et au coût absolue, est un fractile d'ordre  $k_2/(k_1 + k_2)$  de  $\pi(\theta/x)$ .

**Preuve :**

$$\begin{aligned} E^{\pi(\cdot/x)}[L(\theta, \delta(x))] &= \int_{\Theta} L(\xi, \delta(x)) \pi(\xi|x) d\xi \\ &= \int_{\delta(x)}^{+\infty} k_2(\xi - \delta(x)) \pi(\xi|x) d\xi + \int_{-\infty}^{\delta(x)} k_1(\delta(x) - \xi) \pi(\xi|x) d\xi \end{aligned}$$

On remarque que :  $\pi(\xi|x) d\xi = dF(\xi|x) = -d(1 - F(\xi|x))$  et on écrit donc :

$$\begin{aligned} E^{\pi(\cdot/x)}[L(\theta, \delta(x))] &= [k_2(\xi - \delta(x))(1 - F(\xi|x))]_{\delta(x)}^{+\infty} + \int_{\delta(x)}^{+\infty} k_2 P^{\pi(\cdot/x)}(\theta > \xi) d\xi \\ &+ [k_1(\delta(x) - \xi)F(\xi|x)]_{-\infty}^{\delta(x)} + \int_{-\infty}^{\delta(x)} k_1 P^{\pi(\cdot/x)}(\theta < \xi) d\xi \\ &= \int_{\delta(x)}^{+\infty} k_2 P^{\pi(\cdot/x)}(\theta > \xi) d\xi + \int_{-\infty}^{\delta(x)} k_1 P^{\pi(\cdot/x)}(\theta < \xi) d\xi \end{aligned}$$

On dérive par rapport à  $\delta(x)$ , il vient :

$$\begin{aligned}\frac{\partial}{\partial \delta(x)} \rho(\pi, \delta(x)) &= -k_2 P^{\pi(\cdot|x)}(\theta > \delta(x)) + k_1 P^{\pi(\cdot|x)}(\theta < \delta(x)) = 0 \\ \iff -k_2(1 - P^{\pi(\cdot|x)}(\theta > \delta(x))) + k_1 P^{\pi(\cdot|x)}(\theta < \delta(x)) &= 0 \\ \iff (k_1 + k_2) P^{\pi(\cdot|x)}(\theta < \delta(x)) - k_2 &= 0\end{aligned}$$

d'où

$$P^{\pi(\cdot|x)}(\theta < \delta(x)) = \frac{k_2}{k_1 + k_2}.$$

et le coût est donc maximisé pour  $\tilde{\theta} = \delta(x)$  tel que  $P^{\pi(\cdot|x)}(\theta < \delta(x)) = k_2/(k_1 + k_2)$ .

On rappelle : si  $f$  est intégrable sur  $[a, b]$  alors  $F(x) = \int_a^x f(t)dt$ ,  $a < x < b$ , est différentiable p.p. et  $F' = f$  p.p.

### 3.1.3 Coût 0-1

**Définition 8** – On appelle coût 0-1, l'application  $L$  définie par :

$$L(\theta, \delta(x)) = \begin{cases} 0 & \text{si la décision est bonne} \\ 1 & \text{sinon.} \end{cases}$$

On retrouve en utilisant cette fonction de coût, les résultats de la théorie des tests d'hypothèses. Un problème de test est un problème de choix (de prise de décision) entre  $H_0 : \theta \in \Theta_0$  et  $H_1 : \theta \in \Theta_1$ .

On définit donc la décision de la manière suivante :

$\delta(X) = 1$  : on accepte  $H_0$  ;

$\delta(X) = 0$  : on rejette  $H_0$ . (n.b. : ceci ne dépend pas de  $\theta$ ).

On a un espace d'actions de la forme :  $A = \{0, 1\}$ .

Soit  $W$  la région de rejet i.e. le sous-ensemble de  $\mathfrak{X}$  qui conduit à rejeter  $H_0$ . On peut construire une fonction de coût de la manière suivante : supposons  $\theta \in \Theta_0$ ,

si  $X \in W$ , on prend la décision de rejeter i.e.  $\delta(X) = 0$ , mais la décision n'est pas bonne, on va pénaliser et  $L(\theta, \delta(x)) = 1$ .

si  $X \notin W$ , on ne rejette pas, on prend la décision  $\delta(X) = 1$ , la décision est bonne  $L(\theta, \delta(X)) = 0$ .

Le coût s'écrit donc :

$$L(\theta, \delta(x)) = \begin{cases} 1 - \delta(x) & \text{si } \theta \in \Theta_0 \\ \delta(x) & \text{sinon.} \end{cases}$$

Ce qu'on peut écrire :  $L(\theta, \delta(x)) = \mathbf{1}(x \in W)$  et on calcule la fonction de risque :

$$R(\theta, \delta) = E[L(\theta, \delta(X))] = \int_{\mathfrak{X}} L(\theta, \delta(x)) dp_{\theta}(x) = P_{\theta}(x \in W), \quad \theta \in \Theta_0.$$

On retrouve le risque de première espèce.

□